Notes de cours

Sommes et transformations

Pour une variable aléatoire finie X, prenant les valeurs x_i avec probabilités p_i,

$$E(X) = \sum_i x_i p_i, \qquad V(X) = \sum_i (x_i - E(X))^2 p_i = E(X^2) - E(X)^2.$$

L'écart type est $\sigma(X) = \sqrt{V(X)}$. En développant le carré dans $V(aX+b)$, le décalage b s'élimine et le facteur a est élevé au carré. Pour des variables aléatoires finies X, Y et des réels a, b,

$$E(X+Y) = E(X) + E(Y), \quad E(aX+b) = aE(X) + b, \quad V(aX+b) = a^2 V(X).$$

La linéarité de l'espérance ne demande pas l'indépendance. Si X, Y sont indépendantes, $V(X+Y) = V(X) + V(Y)$ (admis). Sans cette hypothèse, on ne peut pas appliquer cette formule. L'écart type de $aX+b$ vaut $|a|\sigma(X)$.

Exemple de dépendance. Si $Y = X$, alors $V(X+Y) = V(2X) = 4V(X)$, et non $2V(X)$ dès que $V(X) \neq 0$.

Démonstration pour la binomiale. Écrire $X = B_1 + \cdots + B_n$ avec les indicatrices indépendantes des succès. Chaque B_i vérifie $E(B_i) = p$, $E(B_i^2) = p$ et $V(B_i) = p - p^2$. Par linéarité et additivité sous indépendance, $E(X) = np$, $V(X) = np(1-p)$.

Échantillon et moyenne

Un échantillon de taille n d'une loi est une famille de n variables indépendantes de même loi. Si elles ont espérance μ et variance σ^2, on note $S_n = \sum_{i=1}^{n} X_i$ et $M_n = \frac{S_n}{n}$.

Somme et moyenne

$$E(S_n) = n\mu, \quad V(S_n) = n\sigma^2, \qquad E(M_n) = \mu, \quad V(M_n) = \frac{\sigma^2}{n}, \quad \sigma(M_n) = \frac{\sigma}{\sqrt{n}}.$$

Pour diviser l'écart type de la moyenne par 2, multiplier la taille par 4. La variance de la somme augmente ; celle de la moyenne diminue.

Concentration

Inégalité de Bienaymé-Tchebychev

Pour une variable d'espérance μ, de variance σ^2, et $\delta > 0$,

$$P(|X - \mu| \geq \delta) \leq \frac{\sigma^2}{\delta^2}.$$

Une borne supérieure à 1 reste vraie, mais n'apporte pas d'information supplémentaire ; on peut la remplacer par 1.

Preuve dans le cadre fini. Dans $V(X) = \sum_x (x-\mu)^2 P(X = x)$, ne conserver que les valeurs vérifiant $|x - \mu| \geq \delta$. Chaque carré est alors au moins δ^2. Donc $V(X) \geq \delta^2 P(|X - \mu| \geq \delta)$.

Loi des grands nombres

Appliquée à la moyenne d'un échantillon,

$$P(|M_n - \mu| \geq \delta) \leq \frac{\sigma^2}{n\delta^2} \xrightarrow[n\to\infty]{} 0.$$

C'est la loi des grands nombres dans le cadre considéré : pour une précision fixée, la probabilité d'un écart au moins égal à cette précision tend vers zéro. Ce résultat ne dit pas que chaque réalisation se rapproche de μ de façon monotone.

Choisir une taille suffisante

Pour garantir $P(|M_n - \mu| < \delta) \geq 1 - \alpha$, il suffit de choisir

$$n \geq \frac{\sigma^2}{\alpha\delta^2}.$$

Prendre le plafond. Il s'agit du plus petit entier satisfaisant *cette borne*, pas nécessairement de la taille minimale pour la probabilité exacte.

Pour une fréquence de succès, $\mu = p$ et $\sigma^2 = p(1-p) \leq \frac{1}{4}$. Si p est inconnu, $n \geq \frac{1}{4\alpha\delta^2}$ est une garantie uniforme.

De la loi individuelle à la moyenne

14.1 Décrire une variable non binomiale

Première utilisation : S62.

Exemple résolu – Un coût de réparation

Un coût X en euros prend les valeurs 0, 20 et 50 avec probabilités 0,5, 0,3 et 0,2. $E(X) = 16$, $E(X^2) = 620$, donc $V(X) = 620 - 16^2 = 364$ en euros carrés. L'écart type est $\sqrt{364} \simeq 19{,}08$ euros. La moyenne 16 n'est aucune des valeurs possibles de X ; elle décrit une moyenne théorique sur de nombreuses réalisations.

A1 – Application immédiate X prend les valeurs 1, 2, 4 avec probabilités $1/2$, $1/4$, $1/4$. Vérifier la loi et calculer espérance, variance et écart type.

14.2 Une remise change aussi la dispersion

Première utilisation : S62.

Propriété – Transformation affine

Pour $Y = aX + b$, $E(Y) = aE(X) + b$ et $V(Y) = a^2V(X)$. L'écart type est $|a|\sigma(X)$. L'ajout d'une constante translate toutes les valeurs sans changer leur dispersion.

Exemple résolu – Coût après remise

Pour le coût précédent, une remise de 20 % puis 5 euros de frais donne $Y = 0{,}8X + 5$. Ainsi $E(Y) = 17{,}8$ et $V(Y) = 0{,}64 \times 364 = 232{,}96$. La variance n'est ni $0{,}8V(X) + 5$ ni $0{,}8V(X)$.

A2 – Guidage partiel Pour la loi de l'application précédente, calculer E et V de $Y = 3X - 2$, puis de $Z = -X$. Expliquer pourquoi multiplier par -1 ne change pas la variance.

14.3 L'indépendance intervient dans la variance

Première utilisation : S64.

Propriété – Somme et moyenne

Pour des variables $X_1, \dots, X_n$ de même espérance μ et même variance σ^2, la moyenne M_n a pour espérance μ. Si elles sont indépendantes, $V(M_n) = \sigma^2/n$ et $\sigma(M_n) = \sigma/\sqrt{n}$. La linéarité de l'espérance ne nécessite pas l'indépendance.

Démonstration. Avec $S_n = \sum X_i$, la linéarité donne $E(S_n) = n\mu$. Sous indépendance, l'additivité admise des variances donne $V(S_n) = n\sigma^2$. Multiplier par $1/n$ pour la moyenne multiplie l'espérance par $1/n$ et la variance par $1/n^2$. Pour une Bernoulli, E=p et $V = p(1-p)$; la binomiale, somme de n Bernoulli indépendantes, a donc E=np et $V = np(1-p)$. □

Exemple résolu – Moyenne de cent coûts

Pour cent coûts indépendants de même loi, d'espérance 16 et de variance 364, le total a pour espérance 1600 et variance 36400. Le coût moyen a pour espérance 16 et variance 3,64, d'où un écart type d'environ 1,91 euros.

A3 – Contre-exemple X vaut 0 ou 1 avec probabilité 1/2 chacune. Comparer les variances de $(X_1 + \cdots + X_n)/n$ pour des copies indépendantes, puis pour $X_1 = \cdots = X_n = X$.

14.4 Une garantie suffisante, pas une probabilité exacte

Première utilisation : S73.

Propriété – Bienaymé-Tchebychev

Pour $\delta > 0$, $P(|X - \mu| \geq \delta) \leq V(X)/\delta^2$. Pour une moyenne indépendante, $P(|M_n - \mu| \geq \delta) \leq \sigma^2/(n\delta^2)$. Toute borne peut être ramenée à 1 si elle la dépasse.

Exemple résolu – Taille garantie par la borne

Pour une fréquence de succès de probabilité 1/2, $V(M_n) = 1/(4n)$. On veut un écart strictement inférieur à 0,1 avec probabilité au moins 0,95. Il suffit d'avoir $25/n \leq 0{,}05$, donc $n \geq 500$. Cela donne le plus petit entier satisfaisant cette inégalité suffisante ; cela ne prouve pas que 499 observations échouent réellement.

A4 – Application immédiate Une variable a une variance égale à 9. Quelle taille d'échantillon indépendant garantit, par cette borne, un écart de moyenne strictement inférieur à 0,5 avec une probabilité au moins 0,99 ?

A5 – Comparer deux informations Pour $X \sim \mathcal{B}(10; 1/2)$ et $M = X/10$, calculer exactement $P(|M - 1/2| \geq 0{,}3)$ et comparer à la borne de Tchebychev. Travailler avec les bornes entières exactes.

14.5 Plusieurs échantillons, plusieurs moyennes

Première utilisation : S74 et S77.

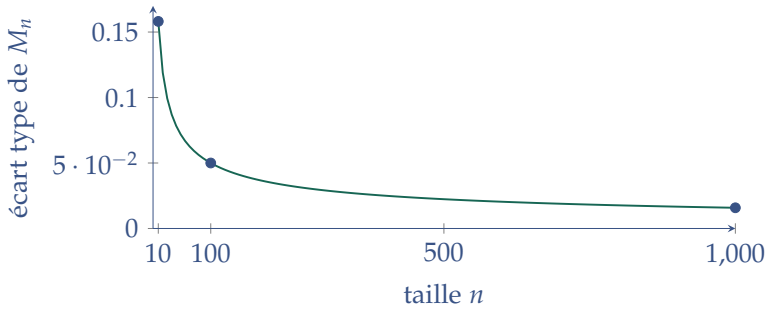


Figure 14.1. Courbe théorique $1/(2\sqrt{n})$: multiplier n par 4 divise l'écart type par 2, pas par 4.

Exemple résolu – Ce que l'on compare

Avec n=100, l'écart type théorique d'une fréquence de succès de probabilité 1/2 vaut 0,05. Une série de 1 000 expériences de 100 essais produit 1 000 moyennes. C'est l'écart type de cette série de moyennes que l'on compare à 0,05 ; les 100 000 résultats individuels ont une autre dispersion.

A6 – TP et interprétation Avec le programme fourni, simuler 1 000 échantillons indépendants de tailles 10,100 et 1 000 pour une Bernoulli de paramètre 1/2. Pour chaque taille, comparer l'écart type observé des moyennes à $1/(2\sqrt{n})$ et compter les écarts d'au moins 0,1. Pourquoi une seule trajectoire de fréquence ne répond-elle pas à cette question ?

A7 – Réfuter « La loi des grands nombres affirme que la fréquence se rapproche de l'espérance à chaque nouveau tirage. » Donner une courte suite de résultats qui éloigne temporairement la fréquence de $1/2$, puis reformuler correctement le résultat.

Une minute à l'oral. Faire une phrase contenant « précision », « risque » et « taille suffisante », puis distinguer cette phrase d'une certitude pour un échantillon particulier.

Reprise différée – S90. Dans un sujet de synthèse, identifier d'abord la loi ou la variance de la moyenne, avant de choisir le seuil.

Activité de recherche

Fluctuations d'une fréquence — 40 min.

On lance indépendamment une pièce équilibrée. Pour tout entier $n \geq 1$, on note F_n la fréquence de « pile » parmi les n premiers lancers.

1. Écrire un programme qui simule 1000 lancers, puis représenter les points $(n ; F_n)$ pour $1 \leq n \leq 1000$. L'écart à $\frac{1}{2}$ diminue-t-il nécessairement à chaque lancer ?
2. Exprimer $E(F_n)$ et $V(F_n)$ en fonction de n.
3. À l'aide de Bienaymé-Tchebychev, majorer $P(|F_{1000} - \frac{1}{2}| \geq 0{,}05)$.
4. Déterminer un entier n suffisant pour que $P(|F_n - \frac{1}{2}| < 0{,}05) \geq 0{,}99$.
5. Préciser ce que montre la trajectoire simulée et ce que garantit l'inégalité obtenue. Une seule simulation constitue-t-elle une preuve de cette garantie ?