Statistiques descriptives à une variable

Cours et exemples

Effectifs, fréquences et moyenne

Une série décrit un caractère sur une population. Si la valeur x_i apparaît n_i fois, n_i est son effectif. L'effectif total non nul est $N = \sum_{i=1}^{p} n_i$; sa fréquence est $f_i = n_i/N$. La moyenne est

$$\overline{x} = \frac{\sum_{i=1}^{p} n_i x_i}{N} = \sum_{i=1}^{p} f_i x_i.$$

L'étendue est $x_{\max} - x_{\min}$.

Effectifs, fréquences et moyenne

On étudie les pointures de 30 élèves :

36	42	40	41	41	38	39	43	42	42	42	40	36	40	39
41	40	38	44	42	40	42	43	38	43	36	41	41	44	43

Compléter les effectifs, calculer les fréquences, la moyenne et l'étendue.

Correction : Effectifs, fréquences et moyenne

Effectifs : $3, 0, 3, 2, 5, 5, 6, 4, 2$, de somme 30. Les fréquences sont ces effectifs divisés par 30, soit en pourcentage 10 ; 0 ; 10 ; environ 6,67 ; 16,67 ; 16,67 ; 20 ; 13,33 ; 6,67. $\sum n_i x_i = 1217$, donc $\bar{x} = 1217/30 \approx 40{,}57$. L'étendue vaut 8. La moyenne n'est pas forcément une valeur de la série. La somme des pourcentages arrondis peut différer légèrement de 100.

Médiane et effectifs cumulés

Une médiane est un nombre tel qu'au moins la moitié des valeurs lui soient inférieures ou égales, et au moins la moitié supérieures ou égales. Dans la série ordonnée de N valeurs, si N est impair, prendre le rang $(N+1)/2$; si N est pair, choisir la moyenne des valeurs de rangs $N/2$ et $N/2+1$.

Médiane et effectifs cumulés

Avec des répétitions, plus de 50 % des valeurs peuvent être inférieures ou égales à la médiane.

Médiane et effectifs cumulés

Compléter les effectifs cumulés croissants (ECC) des pointures et déterminer la médiane.

Correction : Médiane et effectifs cumulés

Les rangs centraux sont 15 et 16. Les ECC passent de 13 pour 40 à 18 pour 41 : les deux valeurs centrales valent 41, donc $M_e = 41$. Au moins la moitié des pointures sont inférieures ou égales à 41, et au moins la moitié supérieures ou égales à 41.

Médiane et effectifs cumulés

Calculer les médianes de $1; 2; 2; 8; 9$ et de $1; 2; 8; 9$.

Correction : Médiane et effectifs cumulés

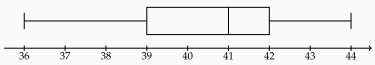
La troisième valeur de la première série vaut 2. Dans la seconde, $(2+8)/2 = 5$; la médiane choisie n'est pas une valeur de la série.

Quartiles et diagramme en boîte

Le premier quartile Q_1 est la valeur de rang $\lceil N/4 \rceil$: la plus petite valeur de la série telle qu'au moins 25 % des valeurs lui soient inférieures ou égales. Q_3 est la valeur de rang $\lceil 3N/4 \rceil$. L'écart interquartile est $Q_3 - Q_1$. Le diagramme en boîte indique minimum, Q_1, médiane, Q_3, maximum.

Quartiles et diagramme en boîte

Déterminer Q_1, Q_3 et l'écart interquartile des pointures, puis tracer le diagramme en boîte.



Correction : Quartiles et diagramme en boîte

$N/4 = 7{,}5$: rang 8, donc $Q_1 = 39$. $3N/4 = 22{,}5$: rang 23, donc $Q_3 = 42$. Écart interquartile 3. Le diagramme utilise $(36; 39; 41; 42; 44)$.

Quartiles et diagramme en boîte

Déterminer les quartiles de $1; 2; 2; 3; 4; 4; 4; 5$. Y a-t-il exactement $25\,\%$ des valeurs inférieures ou égales à Q_1 ?

Correction : Quartiles et diagramme en boîte

$Q_1 = 2$ (rang 2), $Q_3 = 4$ (rang 6). Ici $3/8 = 37{,}5\,\%$ des valeurs sont inférieures ou égales à Q_1. Il faut dire « au moins ».

Ajout ou suppression d'une valeur

Ajouter a à une série de taille N donne $\bar{x}' = (N\bar{x} + a)/(N+1)$. Retirer une occurrence de a, pour $N > 1$, donne $\bar{x}' = (N\bar{x} - a)/(N-1)$. Utiliser la somme exacte, sans arrondi intermédiaire. Réexaminer la médiane dans la nouvelle série ordonnée.

Ajout ou suppression d'une valeur

Dans la série des pointures, la somme vaut 1217, la médiane 41.

1. Ajouter une pointure 36 et calculer les nouveaux indicateurs.
2. Repartir de la série initiale, retirer une pointure 44 et recommencer.

Correction : Ajout ou suppression d'une valeur

1. Somme 1253, effectif 31 : $\bar{x}' = 1253/31 \approx 40{,}42$. Le rang central 16 donne toujours 41. 2. Somme 1173, effectif 29 : $\bar{x}'' = 1173/29 \approx 40{,}45$. Le rang central 15 donne 41. La moyenne diminue dans les deux cas ; la médiane reste inchangée. Les situations sont indépendantes.

Ajout ou suppression d'une valeur

Justifier qu'ajouter la moyenne ne change pas la moyenne. L'étendue peut-elle diminuer lors d'un ajout ?

Correction : Ajout ou suppression d'une valeur

Si $a = \bar{x}$, $(N\bar{x} + \bar{x})/(N+1) = \bar{x}$. Lors d'un ajout, le minimum ne peut qu'être conservé ou diminuer, le maximum être conservé ou augmenter : l'étendue ne diminue pas. Lors d'une suppression, elle n'augmente pas.

Variance et écart type

$V = \dfrac{\sum n_i (x_i - \overline{x})^2}{N}$ est la variance ; $\sigma = \sqrt{V}$ est l'écart type. Il mesure la dispersion autour de la moyenne et a la même unité que les données. On peut aussi calculer $V = \dfrac{\sum n_i x_i^2}{N} - \overline{x}^2$.

Variance et écart type

Calculer la variance et l'écart type des pointures.

Correction : Variance et écart type

$\sum n_i x_i^2 = 49519$, donc

$$V = \frac{49519}{30} - \left(\frac{1217}{30}\right)^2 = \frac{4481}{900} \approx 4{,}979.$$

$\sigma = \sqrt{4481}/30 \approx 2{,}23$. L'écart type n'est pas la distance maximale à la moyenne.

Variance et écart type

Comparer $A : 8; 10; 12$ et $B : 0; 10; 20$ avec les couples moyenne-écart type et médiane-écart interquartile.

Correction : Variance et écart type

Les moyennes et médianes valent toutes 10. $V_A = 8/3$, $\sigma_A \approx 1{,}63$; $V_B = 200/3$, $\sigma_B \approx 8{,}16$. Quartiles : $8, 12$ pour A ; $0, 20$ pour B. Écarts interquartiles 4 et 20. B est beaucoup plus dispersée malgré des centres identiques.

Linéarité de la moyenne

Remplacer chaque x_i par $kx_i + c$ donne une moyenne $k\bar{x} + c$, un écart type $|k|\sigma$ et une variance $k^2 V$. Ajouter une constante ne change ni variance ni écart type.

Linéarité de la moyenne

Moyenne initiale 12/20, écart type 3. Calculer les nouveaux indicateurs pour trois modifications indépendantes, sans plafonnement des notes : ajouter 1,5 ; multiplier par 0,8 ; multiplier par 1,1 puis ajouter 0,5.

Correction : Linéarité de la moyenne

Moyennes : 13,5, 9,6, 13,7. Écarts types : 3, 2,4, 3,3. Multiplier les notes par 1,1 les augmente ; cela ne signifie pas augmenter la difficulté de l'évaluation. Avec un plafonnement à 20, la transformation ne serait plus affine sur toutes les données.

Python

```
from math import sqrt

def moyenne_ecart_type(valeurs):
    n = len(valeurs)
    if n == 0:
        raise ValueError("liste vide")
    m = sum(valeurs)/n
    v = sum((x-m)**2 for x in valeurs)/n
    return m, sqrt(v)
```

Linéarité de la moyenne

Expliquer le programme ; prévoir son résultat pour `[8, 10, 12]`.

Correction : Linéarité de la moyenne

Il vérifie que la liste est non vide, calcule la moyenne, la moyenne des carrés des écarts, puis sa racine. Résultat : $(10; \sqrt{8/3}) \approx (10; 1{,}633)$.

Séries continues regroupées en classes

Une variable quantitative continue peut prendre toutes les valeurs d'un intervalle. Ici, les observations sont regroupées en classes de même amplitude ; le centre de $[a; b[$ vaut $(a + b)/2$. Si les moyennes m_i des classes sont connues, la moyenne globale exacte est $\sum n_i m_i / N$. À défaut, les remplacer par les centres donne une estimation justifiée par un modèle uniforme dans chaque classe.

Séries continues regroupées en classes

Compléter, estimer la moyenne à partir des centres et déterminer la classe médiane.

Correction : Séries continues regroupées en classes

Amplitude 10 cm, effectif total 100. Fréquences en pourcentage : $8, 22, 35, 28, 7$. Centres : $155, 165, 175, 185, 195$ cm. La somme pondérée des centres vaut 17540, donc la moyenne estimée est 175,4 cm. Les rangs centraux $50, 51$ se trouvent dans $[170; 180[$, classe médiane.

Séries continues regroupées en classes

Si les moyennes exactes des classes étaient $154; 166; 174; 184; 196$ cm, quelle serait la moyenne globale ?

Correction : Séries continues regroupées en classes

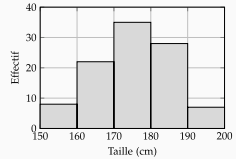
$$(8 \times 154 + 22 \times 166 + 35 \times 174 + 28 \times 184 + 7 \times 196)/100 = 174{,}98 \text{ cm}.$$

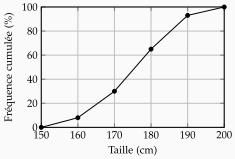
Histogramme et fréquences cumulées

L'aire de chaque rectangle d'un histogramme est proportionnelle à l'effectif. À amplitudes égales, les hauteurs peuvent être les effectifs. Le polygone des fréquences cumulées joint les points (borne supérieure ; fréquence cumulée), en commençant à la première borne inférieure avec 0.

Histogramme et fréquences cumulées

Construire les deux graphiques pour les tailles de l'exemple précédent.





Histogramme et fréquences cumulées

Sous l'hypothèse d'uniformité dans $[170; 180[$, la fréquence cumulée passe linéairement de 30 % à 65 %. Rechercher l'abscisse correspondant à 50 %.

Histogramme et fréquences cumulées

Calculer cette estimation et préciser sa portée.

Correction : Histogramme et fréquences cumulées

On résout $(m - 170)/10 = (50 - 30)/(65 - 30)$, d'où $m = 170 + 10 \times 20/35 \approx 175{,}71$ cm. Il s'agit d'une estimation sous hypothèse d'uniformité, pas de la médiane exacte des données individuelles. Les effectifs des classes seuls ne déterminent pas cette dernière.