Croisement de deux variables qualitatives

Cours et exemples

Tableaux croisés et fréquences marginales

Une variable qualitative décrit une catégorie. Elle est nominale si ses modalités n'ont pas d'ordre naturel (moyen de transport), ordinale si elles sont ordonnées (degré de satisfaction). Un tableau croisé compte les individus selon deux variables. Les sommes des lignes et colonnes sont les marges. Une fréquence marginale divise une marge par l'effectif total.

Tableaux croisés et fréquences marginales

Dans une population de 100 individus, on observe deux caractères A, B :

Correction : Tableaux croisés et fréquences marginales

$f(A) = 32/100 = 0{,}32$; $f(B) = 35/100 = 0{,}35$; $f(\overline{B}) = 65/100 = 0{,}65$. La fréquence de $A \cap B$ est $20/100 = 0{,}20$; ce n'est pas une fréquence marginale.

Tableaux croisés et fréquences marginales

Une classe de Première de 32 élèves est répartie ainsi. Compléter les marges et calculer les fréquences marginales « NSI » et « filles ».

Correction : Tableaux croisés et fréquences marginales

$f(\text{NSI}) = 21/32 = 65{,}625\,\%$; $f(\text{filles}) = 14/32 = 43{,}75\,\%$.

Fréquences conditionnelles et lecture de phrases

La fréquence de A parmi les individus de B, si cette sous-population est non vide, est

$$f_B(A) = \frac{\text{effectif vérifiant } A \text{ et } B}{\text{effectif de } B}.$$

Le dénominateur correspond à la population introduite par « parmi ».

Fréquences conditionnelles et lecture de phrases

Dans le tableau NSI, calculer la fréquence de filles parmi les élèves sans NSI, puis la fréquence des élèves sans NSI parmi les filles. Les deux résultats sont-ils égaux ?

Correction : Fréquences conditionnelles et lecture de phrases

Parmi les 11 élèves sans NSI, 5 sont des filles : $5/11 \approx 45{,}45\,\%$. Parmi les 14 filles, 5 ne font pas NSI : $5/14 \approx 35{,}71\,\%$. Le numérateur est le même, les populations de référence diffèrent.

Fréquences conditionnelles et lecture de phrases

Dans le tableau de 100 individus, calculer $f_B(A)$, $f_A(B)$ et $f_{\overline{A}}(B)$. Traduire chaque résultat par une phrase.

Correction : Fréquences conditionnelles et lecture de phrases

$f_B(A) = 20/35 = 4/7 \approx 57{,}14\,\%$ des individus de B vérifient A. $f_A(B) = 20/32 = 62{,}5\,\%$ des individus de A vérifient B. $f_{\overline{A}}(B) = 15/68 \approx 22{,}06\,\%$ des individus ne vérifiant pas A vérifient B.

Fréquences conditionnelles et lecture de phrases

« 60 % des cyclistes sont des élèves » permet-il de conclure que 60 % des élèves sont cyclistes ?

Correction : Fréquences conditionnelles et lecture de phrases

Non. Par exemple, sur 10 cyclistes, 6 sont élèves ; si la population compte 100 élèves au total, seulement 6 % des élèves sont cyclistes.

Compléter un tableau à partir de fréquences

Un groupe compte 200 personnes, dont 120 utilisent un bus (B). Parmi ces 120 personnes, 75 % possèdent un abonnement (A). Parmi les 80 autres, 25 % possèdent un abonnement.

1. Construire le tableau croisé $B/\overline{B}$ et $A/\overline{A}$ avec ses marges.
2. Calculer la fréquence marginale de A.
3. Calculer la fréquence de B parmi A.

Correction : Compléter un tableau à partir de fréquences

Dans B, $120 \times 0{,}75 = 90$ personnes vérifient A, donc 30 ne le vérifient pas. Dans $\overline{B}$, $80 \times 0{,}25 = 20$ vérifient A, et 60 ne le vérifient pas.

	A	$\overline{A}$	Total
B	90	30	120
$\overline{B}$	20	60	80
Total	110	90	200

$f(A) = 110/200 = 55\,\%$. $f_A(B) = 90/110 = 9/11 \approx 81{,}82\,\%$.

Compléter un tableau à partir de fréquences

Un titre annonce « Trois abonnés sur quatre prennent le bus », en s'appuyant sur $f_B(A) = 75\,\%$.
Expliquer l'erreur et proposer une phrase correcte.

Correction : Compléter un tableau à partir de fréquences

Le titre inverse le conditionnement. La phrase correcte est : « Trois personnes sur quatre parmi celles qui prennent le bus possèdent un abonnement. » La proportion des abonnés qui prennent le bus vaut ici environ 81,82 %.

Python

```
# Exemple fictif : (transport, satisfaction)
donnees = [("bus", "oui"), ("marche", "oui"),
           ("bus", "non"), ("velo", "oui"),
           ("bus", "oui"), ("marche", "non")]

bus = [r for r in donnees if r[0] == "bus"]
bus_satisfaits = [r for r in donnees
                  if r[0] == "bus" and r[1] == "oui"]
autres = [r for r in donnees if not r[0] == "bus"]
```

Traiter un fichier et recueillir des données réelles

Donner les effectifs des trois listes. Calculer la fréquence de satisfaction parmi les usagers du bus. Remplacer `and` par `or` dans le second filtre : combien de lignes sont alors sélectionnées ?

Correction : Traiter un fichier et recueillir des données réelles

Effectifs : $3, 2, 3$. Parmi les usagers du bus, la fréquence de satisfaction vaut $2/3$. Avec `or`, on sélectionne les 3 usagers du bus et les 2 personnes satisfaites utilisant un autre moyen : 5 lignes, sans compter deux fois les lignes qui vérifient les deux critères.

Traiter un fichier et recueillir des données réelles

Recueillir anonymement deux variables : moyen de transport principal et durée du trajet par catégories ordonnées (< 15 min ; de 15 à moins de 30 min ; ≥ 30 min). Une ligne par réponse, sans nom. Construire le tableau croisé, puis deux fréquences conditionnelles de sens opposés. Présenter effectif, date de collecte et éventuelles non-réponses.

Traiter un fichier et recueillir des données réelles

Réaliser la collecte et rédiger deux conclusions justifiées. Expliquer pourquoi les résultats ne décrivent pas automatiquement tous les élèves de Madagascar.

Correction : Traiter un fichier et recueillir des données réelles

Les valeurs dépendent de la collecte réelle. Vérifier : une catégorie par variable et par réponse ; somme des cellules égale au nombre de réponses exploitables ; dénominateur correct pour chaque fréquence ; arrondi annoncé. L'échantillon est une classe particulière, pas un échantillon représentatif de tous les élèves du pays. Les non-réponses doivent être distinguées d'une modalité observée.