Statistiques

Cours et exemples

Comparer les séries $A = (8, 8, 8, 8, 8)$ et $B = (4, 6, 8, 10, 12)$. Elles ont la même moyenne. Sont-elles pourtant semblables ? Proposer une mesure de la dispersion, puis confronter les propositions à la variance et à l'écart-type.

Objectifs

- Organiser des données statistiques : variable discrète et continue.
- Calculer et interpréter les indicateurs de position : moyenne, médiane, mode.
- Calculer et interpréter les indicateurs de dispersion : étendue, variance, écart-type.
- Construire et lire les représentations graphiques : diagramme en bâtons, diagramme circulaire, histogramme.

Statistiques descriptives

Pour une série non vide de valeurs $x_1, \ldots, x_n$:

- **Moyenne** : $\bar{x} = \dfrac{1}{n} \displaystyle\sum_{i=1}^{n} x_i$.
- **Médiane** Q_2 : valeur centrale une fois les données triées.
- **Quartiles** Q_1, Q_3 : valeurs aux rangs $\lceil n/4 \rceil$ et $\lceil 3n/4 \rceil$ dans la série triée.
- **Écart-type** : $\sigma = \sqrt{\dfrac{1}{n} \displaystyle\sum_{i=1}^{n} (x_i - \bar{x})^2}$.

Caractéristiques complémentaires

Le **mode** d'une série statistique est la valeur (ou la classe) qui apparaît le plus souvent. Dans une distribution en classes, on parle de **classe modale**.

Caractéristiques complémentaires

La **fréquence** d'une valeur x_i est $f_i = n_i/N$. La **fréquence cumulée croissante** jusqu'à x_k est $F_k = \sum_{i \leq k} f_i$. La médiane se détermine par les rangs centraux dans la série triée. La fréquence cumulée n'atteint pas forcément exactement 50%.

Séries statistiques groupées

Pour n valeurs $x_1, \ldots, x_p$ aux effectifs $n_1, \ldots, n_p$ (avec $N = \sum n_i$), la **fréquence** de x_i est $f_i = n_i / N$.

Séries statistiques groupées

- **Moyenne :** $\bar{x} = \dfrac{1}{N} \sum_{i=1}^{p} n_i x_i$.
- **Médiane :** valeur Q_2 partageant la série en deux moitiés égales.
- **Mode :** valeur (ou classe) de plus grande fréquence.
- **Quartiles :** Q_1 (25%), Q_2 (50%), Q_3 (75%).

Séries statistiques groupées

- **Étendue :** $e = x_{\max} - x_{\min}$.
- **Variance :** $V = \dfrac{1}{N}\sum_{i=1}^{p} n_i(x_i - \bar{x})^2 = \overline{x^2} - \bar{x}^2$ (variance = moyenne des carrés moins carré de la moyenne).
- **Écart-type :** $\sigma = \sqrt{V}$.

Séries statistiques groupées

1. Trier les valeurs dans l'ordre croissant.
2. Calculer les effectifs cumulés.
3. La médiane est :
   - si N est impair : la valeur de rang $(N+1)/2$.
   - si N est pair : la demi-somme des valeurs de rangs $N/2$ et $N/2+1$.

Séries statistiques groupées

Pour des données connues seulement par classes, remplacer les valeurs par les centres donne une **estimation** de la moyenne et de la variance. La médiane exacte n'est pas déterminée par les seuls effectifs des classes. Les estimations par interpolation supposent une répartition uniforme dans chaque classe. Dans un histogramme, ce sont les **aires** des rectangles qui sont proportionnelles aux effectifs ; pour des amplitudes inégales, les hauteurs sont proportionnelles à effectif/amplitude.