Organisation des données et statistique

Cours et exemples

Objectifs

Calculer proportions et évolutions, résumer une série par ses indicateurs et interpréter une boîte à moustaches.

Proportion et évolution

Une proportion est un rapport partie/ensemble, avec effectif total non nul. Le taux d'évolution d'une valeur initiale $V_i > 0$ à une valeur finale V_f est $t = (V_f - V_i)/V_i$. Le coefficient multiplicateur est $1 + t$; un taux de $p\%$ vaut $p/100$.

Proportion et évolution

Pour des valeurs strictement positives, deux évolutions successives de taux $t_1, t_2 > -1$ ont pour coefficient $(1 + t_1)(1 + t_2)$; leur taux global est ce produit moins 1. Si $t > -1$, le taux réciproque est $1/(1 + t) - 1$.

Proportion et évolution

La valeur finale après deux évolutions vaut $V_i(1+t_1)(1+t_2)$. Pour revenir en arrière, multiplier par l'inverse du coefficient.

Proportion et évolution

Hausse de 20% puis baisse de 20% : coefficient $1{,}2 \times 0{,}8 = 0{,}96$, baisse globale 4%. Passer de 30% à 40% est une hausse de 10 points de pourcentage, mais une hausse relative de $1/3$, soit environ 33,3%.

Indicateurs de position

Pour une série ordonnée $x_1 \leq \cdots \leq x_N$, $N \geq 1$, la moyenne est $\bar{x} = \frac{1}{N} \sum x_i$; avec des effectifs n_j, elle vaut $\sum n_j x_j / \sum n_j$. La médiane est la valeur centrale si N est impair, la moyenne des deux centrales si N est pair.

Indicateurs de position

Q_1 est la valeur de rang $\lceil N/4 \rceil$, Q_3 celle de rang $\lceil 3N/4 \rceil$. Le décile D_k est la valeur de rang $\lceil kN/10 \rceil$, $k = 1, \ldots, 9$. $\lceil a \rceil$ désigne le plus petit entier supérieur ou égal à a. Ces conventions sont précisées car elles peuvent différer selon les logiciels.

Dispersion et représentation

L'étendue vaut maximum moins minimum ; l'écart interquartile vaut $Q_3 - Q_1$. La variance descriptive vaut $V = \frac{1}{N}\sum (x_i - \bar{x})^2$; l'écart type est $\sigma = \sqrt{V}$. Une boîte à moustaches représente minimum, Q_1, médiane, Q_3, maximum, selon la convention utilisée ici.

Dispersion et représentation

$V = \frac{1}{N} \sum x_i^2 - \bar{x}^2$. La variance est positive ou nulle, et vaut zéro exactement lorsque toutes les valeurs sont égales.

Développer les carrés et utiliser $\sum x_i = N\bar{x}$. La première définition est une moyenne de carrés positifs ou nuls ; elle est nulle exactement si chaque carré est nul.

Dispersion et représentation

Série $4, 6, 6, 8, 10, 10, 12, 14$. $N = 8$, somme 70, moyenne 8,75, médiane 9 ; rangs 2 et 6, donc $Q_1 = 6$, $Q_3 = 10$. Étendue 10, écart interquartile 4. Somme des carrés 692 ; variance $86{,}5 - (8{,}75)^2 = 9{,}9375$; écart type $\sqrt{9{,}9375} \simeq 3{,}152$ minutes. La variance s'exprime en minutes carrées.