Variables aléatoires, concentration et loi des grands nombres

Cours et exemples

Objectifs

Calculer espérance et variance d'une somme et d'une moyenne ; appliquer Bienaymé-Tchebychev ; déterminer une taille d'échantillon.

Sommes et transformations

Pour une variable aléatoire finie X, prenant les valeurs x_i avec probabilités p_i,

$$E(X) = \sum_i x_i p_i, \qquad V(X) = \sum_i (x_i - E(X))^2 p_i = E(X^2) - E(X)^2.$$

L'écart type est $\sigma(X) = \sqrt{V(X)}$. En développant le carré dans $V(aX + b)$, le décalage b s'élimine et le facteur a est élevé au carré. Pour des variables aléatoires finies X, Y et des réels a, b,

$$E(X + Y) = E(X) + E(Y), \quad E(aX + b) = aE(X) + b, \quad V(aX + b) = a^2 V(X).$$

La linéarité de l'espérance ne demande pas l'indépendance. Si X, Y sont indépendantes, $V(X + Y) = V(X) + V(Y)$ (admis). Sans cette hypothèse, on ne peut pas appliquer cette formule. L'écart type de $aX + b$ vaut $|a|\sigma(X)$.

Sommes et transformations

Si $Y = X$, alors $V(X + Y) = V(2X) = 4V(X)$, et non $2V(X)$ dès que $V(X) \neq 0$.

Sommes et transformations

Écrire $X = B_1 + \cdots + B_n$ avec les indicatrices indépendantes des succès. Chaque B_i vérifie $E(B_i) = p$, $E(B_i^2) = p$ et $V(B_i) = p - p^2$. Par linéarité et additivité sous indépendance, $E(X) = np$, $V(X) = np(1-p)$.

Échantillon et moyenne

Un échantillon de taille n d'une loi est une famille de n variables indépendantes de même loi. Si elles ont espérance μ et variance σ^2, on note $S_n = \sum_{i=1}^{n} X_i$ et $M_n = \dfrac{S_n}{n}$.

Échantillon et moyenne

$$E(S_n) = n\mu, \quad V(S_n) = n\sigma^2, \qquad E(M_n) = \mu, \quad V(M_n) = \frac{\sigma^2}{n}, \quad \sigma(M_n) = \frac{\sigma}{\sqrt{n}}.$$

Échantillon et moyenne

Pour diviser l'écart type de la moyenne par 2, multiplier la taille par 4. La variance de la somme augmente ; celle de la moyenne diminue.

Concentration

Pour une variable d'espérance μ, de variance σ^2, et $\delta > 0$,

$$P(|X - \mu| \geq \delta) \leq \frac{\sigma^2}{\delta^2}.$$

Une borne supérieure à 1 reste vraie, mais n'apporte pas d'information supplémentaire ; on peut la remplacer par 1.

Concentration

Dans $V(X) = \sum_x (x-\mu)^2 P(X=x)$, ne conserver que les valeurs vérifiant $|x-\mu| \geq \delta$. Chaque carré est alors au moins δ^2. Donc $V(X) \geq \delta^2 P(|X-\mu| \geq \delta)$.

Loi des grands nombres

Appliquée à la moyenne d'un échantillon,

$$P(|M_n - \mu| \geq \delta) \leq \frac{\sigma^2}{n\delta^2} \xrightarrow[n\to\infty]{} 0.$$

C'est la loi des grands nombres dans le cadre considéré : pour une précision fixée, la probabilité d'un écart au moins égal à cette précision tend vers zéro. Ce résultat ne dit pas que chaque réalisation se rapproche de μ de façon monotone.

Loi des grands nombres

Pour garantir $P(|M_n - \mu| < \delta) \geq 1 - \alpha$, il suffit de choisir

$$n \geq \frac{\sigma^2}{\alpha\delta^2}.$$

Prendre le plafond. Il s'agit du plus petit entier satisfaisant *cette borne*, pas nécessairement de la taille minimale pour la probabilité exacte.

Loi des grands nombres

Pour une fréquence de succès, $\mu = p$ et $\sigma^2 = p(1-p) \leq \frac{1}{4}$. Si p est inconnu, $n \geq \frac{1}{4\alpha\delta^2}$ est une garantie uniforme.

Activité de recherche

Fluctuations d'une fréquence - 40 min.

On lance indépendamment une pièce équilibrée. Pour tout entier $n \geq 1$, on note F_n la fréquence de « pile » parmi les n premiers lancers.

Activité de recherche (2)

1. Écrire un programme qui simule 1000 lancers, puis représenter les points $(n; F_n)$ pour $1 \leq n \leq 1000$. L'écart à $\frac{1}{2}$ diminue-t-il nécessairement à chaque lancer ?
2. Exprimer $E(F_n)$ et $V(F_n)$ en fonction de n.
3. À l'aide de Bienaymé-Tchebychev, majorer $P(|F_{1000} - \frac{1}{2}| \geq 0{,}05)$.
4. Déterminer un entier n suffisant pour que $P(|F_n - \frac{1}{2}| < 0{,}05) \geq 0{,}99$.

Activité de recherche (3)

5. Préciser ce que montre la trajectoire simulée et ce que garantit l'inégalité obtenue. Une seule simulation constitue-t-elle une preuve de cette garantie ?